开源软件开发与社区治理报告

组员：张雯怡（51265903051） 胡思勘（51265903082）

任务类型：**OpenPerf**

任务名称：Open source repository collaboration network and npm artifact library dependency network mapping dataset

一、任务描述与目标

本任务将构建一个数据集，其旨在表达 npm 包的依赖网络与开源仓库协作网络之间的映射关系。这一数据集的构建目的是：由于个人贡献和仓库名称更改导致 npm 注册表中元数据不完整或过时，该数据集能够帮助开发者重新从一个仓库出发，映射到 npm 依赖网络的相应的 npm 包所对应的节点，从而找回属于该仓库所需的 npm 依赖包。

我们需要构建开源仓库协作网络和 npm 工件库依赖网络，其信息如下：

- **开源仓库协作网络：**
  节点：代表一个仓库（repo）。
  属性：包括贡献数量、贡献的性质（代码、文档等）以及协作持续时间等指标。
  边：代表仓库间的协作关系（同一开发者在两个 repo 均有贡献）
- **npm 工件库依赖网络：**
  节点：代表单独的 npm 包。
  属性：包括版本号、更新频率和受欢迎程度指标（下载量、描述）。
  边：代表依赖链接，即一个包依赖于另一个包。

由于网络结构的复杂性，两个网络无法完全映射，但两个网络的子集可以具有相应的关系，可以根据 npm 包信息中的 repo_url 字段进行映射。

npm 包以及 npm 依赖数据我们是直接从 X-lab 开源社区所提供的 clickhouse 数据库中直接查询提取的，数据总量在 4 亿左右，我们应当做适当的样本筛选，减少数据量；协作网络的数据则是利用 python 的 requests 模块，通过公共 API 从 GitHub 上收集。

构建完网络后，我们可以定量分析网络的指标，如度数、聚类系数、平均路径长度、直径、中心性、密度、模块性、连通分量等；也可以定性分析网络结构，比如可视化分析。

此外，两个网络映射的分析是本任务很重要的部分，也可以做可视化分析，通过检查依赖链及其对软件可靠性的影响来研究软件生态系统的弹性与趋势。

二、开源协作数据的构建及其网络构建

首先，我们要从 npm 包的 repo 字段中获得到所要处理的这些开源仓库的 url（爬取对象），而在利用 API 爬取数据时，还需要给出仓库的 owner 和 repo 名，这两者蕴含在了 url 中，如下图所示。

owner 和 repo 名的提取需要用正则表达式作用于 url 进行提取，我们所想到的正则表达式的规则是：在 url 中找到第一个“xxx/yyy.git”的形式，然后提取出 xxx 和 yyy，他们分别是 owner 和 repo 名。故正则表达式应为：

```python
## 提取出上述url的owner和repo名对（用以后续爬取贡献信息）
def get_owner_repo(url):
    # 定义正则表达式模式
    pattern = r'\/([^\/]+)\/([^\/]+)\.git(?:\/|$)'
    match = re.search(pattern, url)
    if match:
        o = match.group(1)
        r = match.group(2)
        return o, r        ## 可以返回出来（调用函数时，
```

随后，便可以使用 GitHub 的 API 来构造请求 url，其格式如下：

```
https://api.github.com/repos/<owner>/<repo>/contributors
```

将<owner>替换为我们要处理的仓库所有者，将<repo>替换为仓库名称。通过调用 python 的 requests 库的函数来接收并解析响应，GitHub 的服务器会响应你的请求，并返回一个 JSON 格式的数据包，其中包含了仓库的贡献者信息；调用 requests 的接口来解析 JSON 数据包以获取贡献者的名字，而后写入 pandas 的 DataFrame（使用 pandas 是为了方便），最后持久化到 csv 文件，写入本地磁盘，保存好数据以便后续使用。

这一部分较为麻烦的是，爬取的请求频率是有限制的，为了进行更大量请求，我们在 headers 中写上了 token 进行访问认证；处理时仍然可能出现异常，我们的策略是“有限的重试”，重试到一定上限次数便停止，直接爬取下一个仓库的贡献者信息。

我们将 npm 包中提到的仓库全都保存至一个 list 中，然后对于 list 中的每个仓库，都做上述操作，最终形成的数据形式如下：

repo_name	**contributors**	
levelDB	[‘Alice’,’Bob’,’Jack’]	(后者是 list 类型)
RockDB	[‘Alice’,’Mike’]	
cnnGtb	[‘Jack’, ‘Jerry’, ‘Eric’, ‘Jimm’, ‘Bob’]	

完成数据收集后，即可使用网络分析工具（我们所使用的是 networkx 库）来构建和可视化开源协作网络。

网络上的各个节点代表各个仓库，那么该网络想展示的是各个**仓库之间的协作关系**，我们将这种协作定义为：若某个贡献者 Alice 在开源仓库 repo_1 和 repo_2 均有贡献，那么 repo_1 和 repo_2 这两个仓库具有协作关系。换句话说，如果 repo_1 和 repo_2 **具有至少一个相同的贡献者**，那么它们就具有协作关系，可以在两个仓库间建立一条无向边。

因此，上述代码逻辑可以写成：利用两个 for 循环两两比对 repo 的贡献者，如果两者的贡献者列表**取交集**以后所形成的集合的大小> 0，那么就有共同的贡献者，可以连边。由于时间复杂度是$O(n^2)$，这个程序跑得很慢，所以考虑使用**并行化处理库**。

由于爬取来的数据均为 string 字符串的数据类型，所以我们要先对数据进行预处理，将贡献者列表从字符串格式转换为 Python 列表，并筛除了以[bot]结尾的 bot 账户，确保网络中仅包含人类贡献者。

```python
def str2lst(s):
    str_list = s.strip('[]').split(',')
    return [item.strip("' ") for item in str_list]

def filter_bot(lst):
    return [x for x in lst if not x.endswith('[bot]')]

# 筛除bot账户
repo_contr_df_nobot = deepcopy(repo_contr_df)
repo_contr_df_nobot['developers'] = repo_contr_df.apply(lambda row: filter_bot(str2lst(row['developers'])), axis=1)
```

我们采用了**并行处理**的方法来加速网络构建过程，具体操作流程如下：

- 将数据集分割为多个子集，每个子集对应一个子图；
- 遍历数据子集构建单个子图，为具有共同贡献者的仓库对添加边；

```python
def build_graph_chunk(df_chunk):
    G_chunk = nx.Graph()
    for index, row in df_chunk.iterrows():
        repo1 = row['repo_name']
        developers = set(row['developers'])
        for other_index, other_row in df_chunk.iterrows():
            if other_index != index:
                repo2 = other_row['repo_name']
                if len(developers.intersection(set(other_row['developers']))) > 0:
                    G_chunk.add_edge(repo1, repo2)
    return G_chunk
```

- 利用 concurrent.futures.ProcessPoolExecutor，我们实现了多进程并行处理，每个子集由一个独立的进程处理，以构建其对应的子图；

```python
with ProcessPoolExecutor() as executor:
    # 将数据分块
    num_workers = 10
    chunk_size = len(repo_contr_df_nobot) // num_workers
    futures = []
    for i in range(0, len(repo_contr_df_nobot), chunk_size):
        df_chunk = repo_contr_df_nobot.iloc[i:i + chunk_size]
        futures.append(executor.submit(build_graph_chunk, df_chunk))

    # 获取每个进程的结果
    graphs = [future.result() for future in futures]
```

- 所有子图构建完成后，合并这些子图，形成一个完整的网络。

```python
def merge_graphs(graphs):
    merged_graph = nx.Graph()
    for G in graphs:
        merged_graph = nx.compose(merged_graph, G)
    return merged_graph
```

三、npm 依赖网络的构建

这部分数据不需要爬取，来源于 ClickHouse 数据库，通过 clickhouse_driver 库连接并查询数据，从而可以直接获取比较规整的数据。我们选择了两个主要表：npm_records 和 npm_dependencies，分别包含 npm 包的基本信息和依赖信息。使用 pandas 库读取查询结果，并将其转换为 DataFrame 对象。我们筛选了同时存在于 npm_records 和 npm_dependencies 表中的 package_id，确保了数据的一致性。

```
# 保留共同package_id行
common_package_ids = pd.merge(npm_packages_df[['package_id']], npm_dependencies_df[['package_id']], on='package_id', how='inner')['package_id']
npm_packages_df = npm_packages_df[npm_packages_df['package_id'].isin(common_package_ids)]
npm_dependencies_df = npm_dependencies_df[npm_dependencies_df['package_id'].isin(common_package_ids)]
```

使用 networkx 库创建了一个有向图 G，用于表示 npm 包之间的依赖关系，建图流程：

- 为每个 npm 包创建节点，并将包名映射到包 ID；
- 遍历依赖信息 DataFrame，为存在依赖关系的包对添加边；
- 移除了没有依赖关系（既不是依赖者也不是被依赖者）的孤立节点，以优化该网络的结构。

```
G = nx.DiGraph()

for package_id, package_name in package_id_to_name.items():
    G.add_node(package_name)

num_nodes = G.number_of_nodes()
print("Number of nodes:", num_nodes)

# 添加边（依赖关系）
for index, row in npm_dependencies_df.iterrows():
    package_id = row['package_id']
    dependency_name = row['dependency_name']

    if package_id in package_id_to_name.keys():
        package_name = package_id_to_name[package_id]
        if dependency_name in package_id_to_name.values():
            G.add_edge(package_name, dependency_name)
```

四、网络特征的分析

建立完上述 G 后，我们定量地对它们进行一些指标的度量，包括**节点数、边数、节点的度中心性、网络的聚类系数**（用以描述局部连接紧密度）、**平均路径长度和直径**（用以描述网络整体连接性），从而能够更好地理解图本身的基本特征。两个网络的分析如下图所示：

开源协作网络：

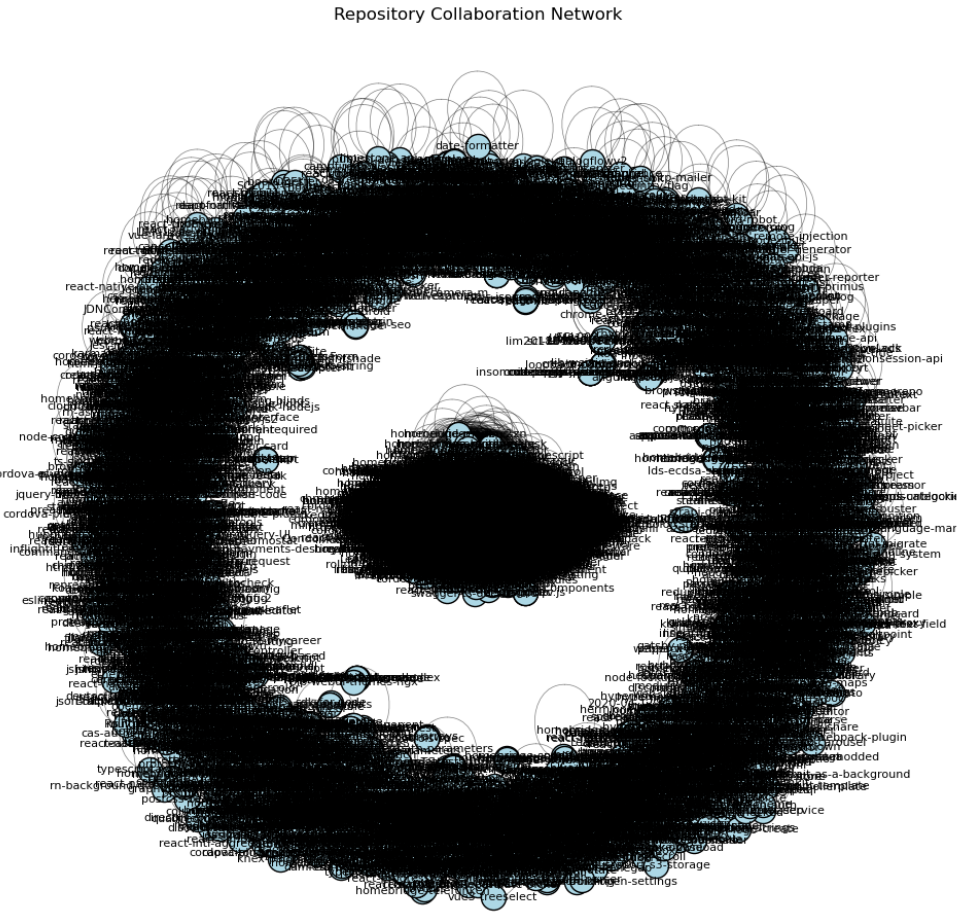

- 节点数：41802　边数：4079123
- 节点的度中心性 top10：

```
Top 10 nodes by degree centrality:
Node: eslint-config, Degree Centrality: 0.21097581397574222
Node: lotide, Degree Centrality: 0.20310518887107964
Node: platzom, Degree Centrality: 0.20068897873256622
Node: cli, Degree Centrality: 0.1877467046242913
Node: utils, Degree Centrality: 0.1778187124709935
Node: core, Degree Centrality: 0.15559436377120164
Node: ui, Degree Centrality: 0.14205401784646302
Node: prettier-config, Degree Centrality: 0.11990143776464678
Node: stylelint-config, Degree Centrality: 0.11521255472357121
Node: censorify, Degree Centrality: 0.10406449606468746
```

- 网络的平均聚类系数（局部连接紧密度）：0.5051
- 平均路径长度和直径（网络整体连接性）：非连通图，无法计算

Npm 依赖网络：

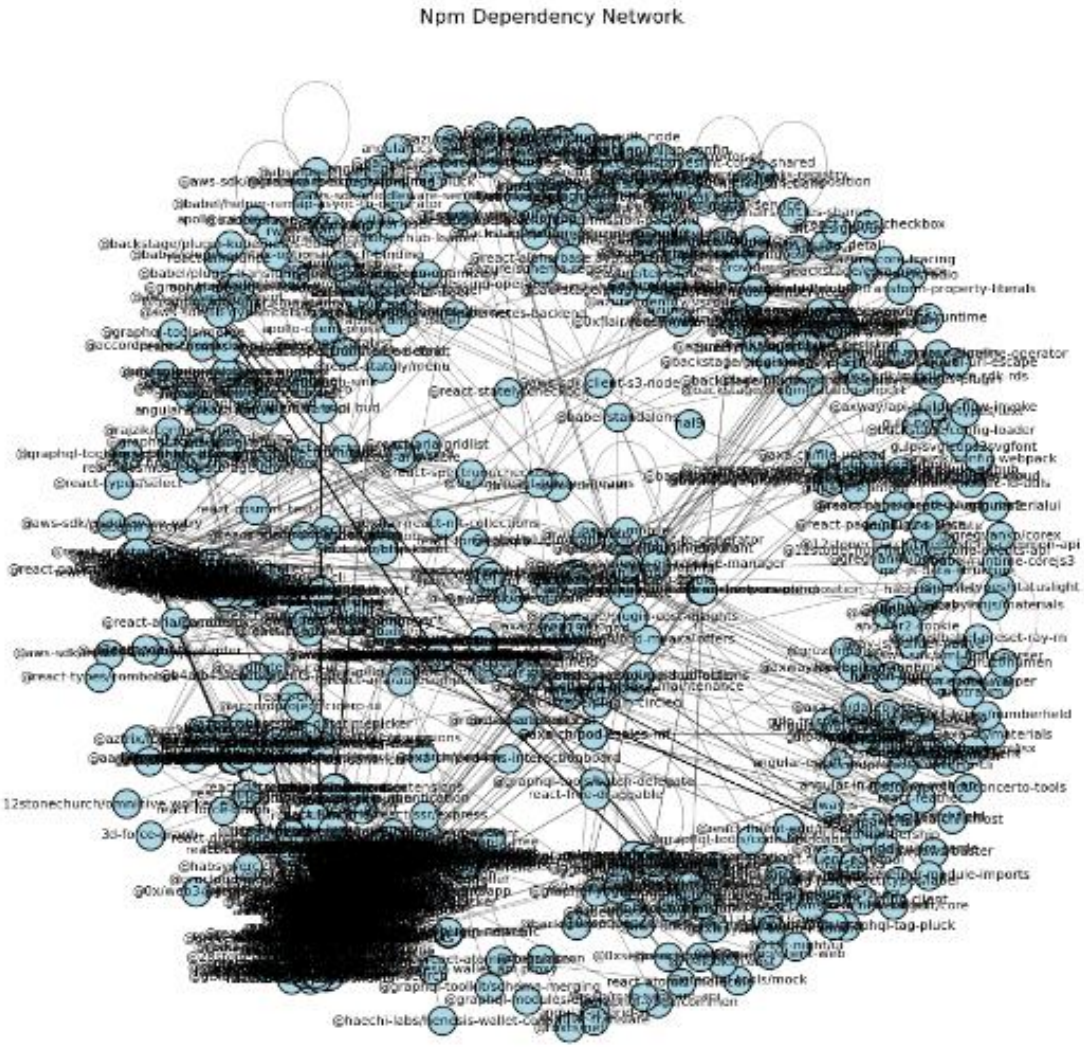

- 节点数：874 边数：1351
- 节点的度中心性 top10：

```
Top 10 nodes by degree centrality:
Node: react-dom, Degree Centrality: 0.4146620847651776
Node: @babel/runtime, Degree Centrality: 0.12485681557846506
Node: antd, Degree Centrality: 0.03780068728522337
Node: @aws-sdk/smithy-client, Degree Centrality: 0.03665521191294387
Node: @aws-sdk/fetch-http-handler, Degree Centrality: 0.035509736540664374
Node: @aws-sdk/middleware-retry, Degree Centrality: 0.035509736540664374
Node: @aws-sdk/middleware-serde, Degree Centrality: 0.035509736540664374
Node: @aws-sdk/middleware-logger, Degree Centrality: 0.027491408934707903
Node: gulp-sourcemaps, Degree Centrality: 0.026345933562428408
Node: @azure/identity, Degree Centrality: 0.022909507445589922
```

- 网络的平均聚类系数（局部连接紧密度）：0.1056
- 平均路径长度和直径（网络整体连接性）：非连通图，无法计算

五、开源协作网络与 npm 依赖网络的映射

我们认为，将各个开源仓库到 npm 包的映射关系。现在有了包含 npm 包名字、repo_url 字段的 csv 数据以及包含 repo_url、贡献者字段的 csv 数据。我们发现，这两个数据可以通过共同的 repo_url 进行自然连接，从而可以通过 repo_url 映射到相应的 npm 包，给开发任务做出指导性意见。

为了使得这样的映射方式简单易用，我们便使用类似于关系型数据库的 JOIN 算子的方式，将 repo_co 表和 npm 表进行连接操作，他们具有共同的字段 repo_name，所以可以使用自然连接的方式。

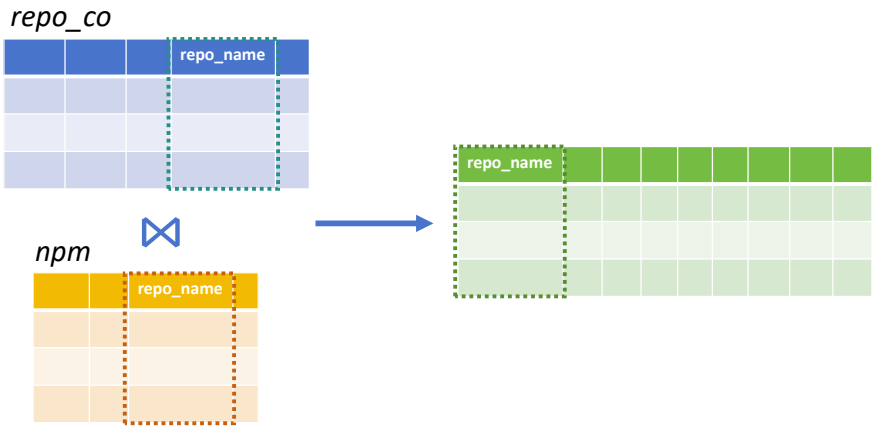

使用 pandas 的接口可以完成。由于我们想从 repo_co 映射到 npm，因此，应当将 repo_co 表作为左表，而 npm 表作为右表。

```
# result = repo_co_df.join(npm_packages_df)
reflection_of_repo_to_npm = pd.merge(repo_co_df, npm_packages_df, on="repo_name", how='inner')
reflection_of_repo_to_npm
```

✓ 0.9s

	repo_name	developers	package_id	name	version	description
0	ng-bootstrap	['maxokorokov', 'pkozlowski-opensource', 'jniz...	1e8f64b6-6252-46ab-bd81-8225986bf593	@mintapp/ng-bootstrap	1.0.0-beta.6-v3	Angular powered Bootstrap
1	ng-bootstrap	['maxokorokov', 'pkozlowski-opensource', 'jniz...	7691ce0e-072b-49a6-bf81-93cfe07d7d6c	@ng-bootstrap/ng-bootstrap	9.1.3	Angular powered Bootstrap
2	ng-bootstrap	['maxokorokov', 'pkozlowski-opensource', 'jniz...	f30e25f8-5ddd-4731-b762-44549bc786d1	@anglr/bootstrap	7.0.1-beta.20200304081421	Angular module wrapping bootstrap components

我们生成的文件是 csv 格式的，便于在其它的开发任务中读取和使用，尤其是使用 pandas 框架来处理 csv 数据是极为方便的。在使用这个数据进行仓库开发中使用 npm 包的指导时，可以遍历数据框，找到开发者所关心的 repo_name 的那些行，然后读取 npm 包，就可以知道，哪些包是和该 repo 相关联的了。

（注：由于生成的数据集太大，超过 1.5GB，因此没有放在我们的 github 仓库里，我把这个文件单独发到助教老师您的邮箱里了，注意查收，麻烦老师了~）

六、发现与结论

在本次任务中，我们深入探索了**开源仓库协作网络与 npm 工件库依赖网络之间的复杂映射关系**，通过构建这两个网络并对其进行详细分析，并且做成了最后的大的数据集。

最初的任务是通过 **GitHub API 收集**了仓库的元数据，包括贡献数量、贡献性质及协作持续时间等关键属性。这些属性不仅揭示了仓库内部的活跃度与协作模式，还通过连边展示了开发者社区中跨项目的合作网络。我们发现，一些核心开发者在多个高影响力仓库中均有显著贡献，这些“桥梁”人物在促进知识流动与技术创新方面发挥了重要作用；而 npm 包的依赖链则揭示了包之间的复杂依赖网络，这一网络不仅是软件构建的基础，也是潜在风险与脆弱性的传播路径。

在将两个网络进行映射的过程中，我们利用 **npm 包信息中的 repo_url 字段作为桥梁**，尽管这一映射并非完全一一对应，但确实为我们提供了有价值的视角来观察开源项目如何转化为 npm 包，并进而影响整个软件生态系统。通过映射分析，我们发现了一些开源仓库虽然活跃度很高，但其对应的 npm 包在生态系统中的影响力却相对有限，这提示我们可能需要更多的推广与集成工作来充分发挥这些仓库的潜力。

对于网络图本身，我们**定量地**计算了网络的度数、聚类系数**等指标**，提供了网络结构的量化描述，例如，高聚类系数可能意味着网络中存在紧密联系的社区结构，而低平均路径长度则表明信息在网络中传播的高效性；我们也**定性地**进行了网络**可视化分析**，直观地展示了网络的拓扑结构与关键节点，从而更好地理解了网络的结构特征，还为我们进一步研究软件生态系统的弹性、**评估软件开发实践**随时间的趋势提供了有力的工具。

上述对于开源仓库协作网络与 npm 工件库依赖网络的构建和分析能够揭示**软件生态系统**内部的复杂**关系**与动态**变化**。这些发现不仅加深了我们对开源软件与 npm 生态系统的理解，还为未来的研究与实践提供了宝贵的参考与启示。

七、未来工作展望

针对上述任务的背景，我们认为未来可以尝试对网络做**社区发现**。社区发现能够将庞大的网络划分成多个社群，直观上来看，则是将细粒度的图转换成了粗粒度的图。通过社区发现算法，我们可以以“社群”为单位来进行映射，解释性或许会更强。

比如说，可以对开源仓库网络进行**社区发现**，建立起各个 npm 包到开源仓库的映射关系，这种关系可以指导各个 npm 包，让他们在提供相应的 npm 资源时，倾向于向映射的一大群开源仓库一同提供 npm 包。

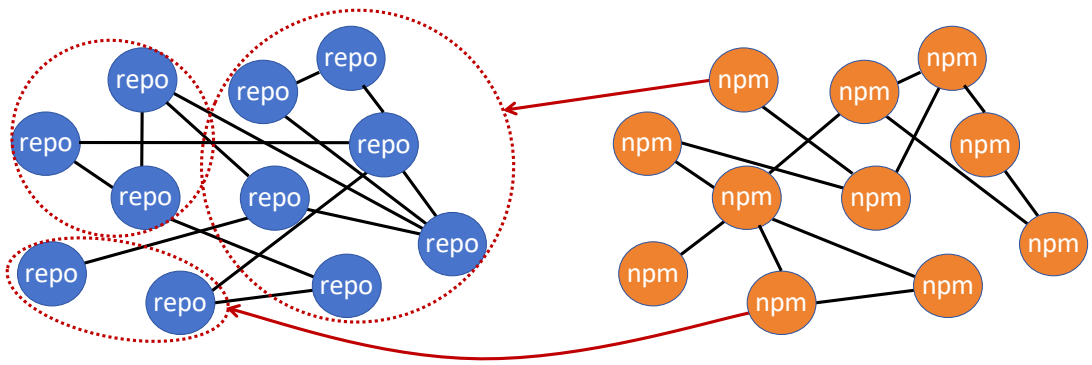

也可以对 npm 依赖网络进行社区发现，建立起各个开源仓库到 npm 包的映射关系，这种关系可以指导各个仓库，让他们了解各自很可能使用到一大群 npm 包，从而可以帮助提高开发效率。

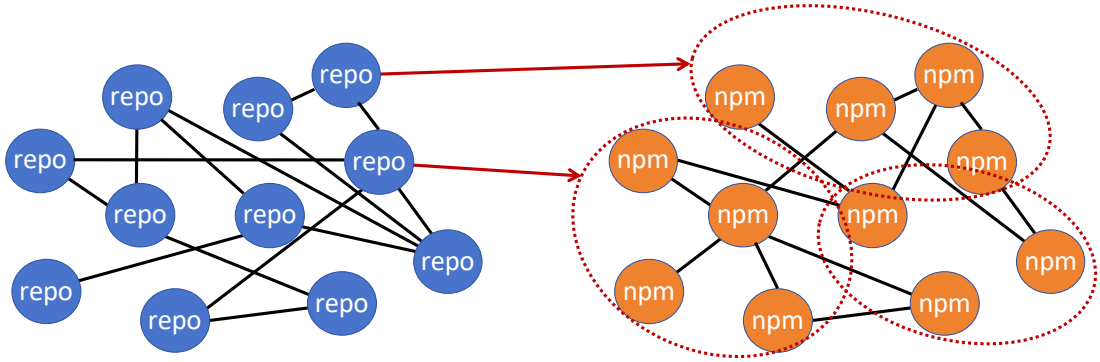

此外，也可以对两个网络都做社区发现，进行相互映射，使得上述映射的粒度变粗。